

環境與人口密度對登革熱確診數影響

研究背景與動機

- 1. 全球登革熱病例近年明顯上升，對公共衛生造成威脅
- 2. 登革熱流行與 氣候與環境因素（氣溫、濕度、空氣污染）密切相關
- 3. 台灣（高雄）具溫暖濕潤氣候，登革熱疫情風險仍高

研究變項

Y（應變數）：每一百萬人中就有幾個人確診登革熱。

$$\text{登革熱確診 ppm} = \frac{\text{登革熱確診數}}{\text{人口數}} * 1000000$$

X（自變數）：空氣品質、人口密度及其他環境因素

資料：

變數名稱	單位	類型	中文說明
station		類別	測站代碼
date	YYYY-MM-DD	datetime	日期
area		類別	北高雄/南高雄
season		類別	季節
max_AMB_TEMP	°C	連續	當日最高溫度
mean_AMB_TEMP	°C	連續	當日平均溫度
max_PM2_5	µg/m³	連續	當日最高 PM2.5
mean_PM2_5	µg/m³	連續	當日平均 PM2.5
max_RH	%	連續	當日最高相對濕度
mean_RH	%	連續	當日平均相對濕度
item_ppm	ppm	連續	登革熱確診率（應變數）

研究方法與結果

資料概述

本研究之登革熱確診率 (ppm) 平均約為 15.8 ppm，作為後續模型誤差解讀之參考尺度。

Random Forest Regression

本研究採用 Random Forest Regression 預測登革熱確診率 (ppm)，並納入氣溫、濕度及空氣污染等環境變數。本研究之重點在於探討不同抽樣方法下模型表現的穩定性，因此選擇 Random Forest Regression。由於 Random Forest 本身即結合 bootstrap 與集成學習，能更清楚呈現抽樣方法對預測誤差分布之影響。

a. k-fold

為評估模型之泛化能力，本研究採用 5-fold cross-validation (n_splits = 5, seed 固定)。每一 fold 分別計算訓練集與測試集之 RMSE，結果彙整如下表。


Fold	RMSE (Train)	RMSE (Test)
Fold 1	4.044976	11.821107
Fold 2	4.497461	10.246235
Fold 3	4.150672	11.523006
Fold 4	4.410568	11.868107
Fold 5	4.331489	11.675742
Mean	4.287033	11.426839
SD	0.186214	0.673645

- Train RMSE 明顯小於 test RMSE，顯示模型具備學習能力。同時，test RMSE 在各 fold 間變化不大，顯示模型未出現嚴重 overfitting，具有良好的泛化能力。

b. bootstrap

為進一步估計模型預測誤差之不確定性，本研究採用 bootstrap resampling (B = 1000, seed 固定, n_estimators = 300)。

Metric	Mean	SD	95% CI
RMSE (ppm)	11.800884	1.906364	[8.27, 15.83]



- Bootstrap 結果顯示 RMSE 分布集中，且 95% 信賴區間範圍合理，顯示模型預測表現具有穩定性。

結論

本研究透過 5-fold cross-validation 與 bootstrap 評估 Random Forest Regression 之預測穩定性。結果顯示，在兩種抽樣方法下 RMSE 表現差異不大，顯示模型具備良好穩定性。考量 5-fold cross-validation 能模擬模型於新資料下的預測表現，且計算效率較高，因此本研究以其作為主要模型效能評估方式，而 bootstrap 則用於輔助估計預測誤差之不確定性。