

基礎統計推論

黃怡婷

國立臺北大學統計系

範例 – 汽車資訊

- Make
- Type
- Origin
- Drivetrain
- Invoice
- Enginesize
- MPG_city
- MPG_Highway
- Weight (LBS)
- Length (IN)

檔案: statpackch7d1.sas7bdat

範例

- 評估治療方式是否有效降低血鉛值
- 資料包含六個變數
 - 編號 (id)
 - 治療組別 (group)
 - 四次血鉛值 (基準時間, 第 1, 4, 6 個月, 變數名稱 : lead0, lead1, lead4, lead6)
- 資料由第 32 列開始
- 資料集 : `statpackch7d2.txt`

範例 -- 網球肘

- 探討影響網球肘（有/沒有）的可能因素
- 變數
 - ID
 - 年齡（年為單位）
 - 性別（1=男； 2=女）
 - 網球肘次數
 - 前一次使用球拍種類（1=正常； 2=稍大； 3=過大）
 - 前一次使用球拍重量（1=重； 2=適中； 3=輕； 4=不知道）
- 前一次使用球拍材質（1=木頭； 2=鋁； 3=玻璃纖維； 4=石墨； 5=鋼； 6=合成； 7=其他）
- 前一次使用球拍線的種類（1=尼龍線； 2=腸線； 3=不知道）
- 這一次使用球拍種類
- 這一次使用球拍重
- 這一次使用球拍材質
- 這一次使用球拍線的種類
- 遺失資料值
 - 9 及 99

資料集：statpackch7d3.txt

統計方法

- 母數統計方法
 - 連續反應變數
 - T 檢定
 - 變異數分析 (Analysis of Variance)
 - 迴歸分析
 - 離散反應變數 (二元)
 - 邏輯斯迴歸
- 無母數統計方法
 - 離散反應變數
 - 卡方檢定
 - 連續反應變數
 - Wilcoxon檢定

假設及檢定

假設 (HYPOTHESIS)

- 虛無假設 (Null hypothesis; H_0)
 - 陳述一般的事實
- 對立假設 (Alternative; H_a)
 - 研究想要得到的結果

對立假設的設定


- 單邊對立假設 (One-sided hypothesis)
 - 知道方向
 - 有網球肘的平均年齡較沒有網球肘的平均年齡大
- 雙邊對立假設 (Two-sided hypothesis)
 - 不知道方向
 - 有網球肘的平均年齡與沒有網球肘的平均年齡不同

範例 -- 網球肘與年齡的關聯

- 虛無假設
 - 平均年齡與網球肘無關
- 對立假設
 - 單邊：有網球肘的平均年齡較沒有網球肘的平均年齡大
 - 雙邊：有網球肘的平均年齡與沒有網球肘的平均年齡不同

檢定統計 (TEST STATISTIC)

- 判定準則
- 可決定是否資料支持研究想要得到的結果





錯誤的種類 (TYPE OF ERRORS)

- 利用判定準則會造成二種錯誤
 - 型一誤 (Type I error)
 - 型二誤 (Type II error)

檢定結果	真實狀態 (True state of nature)	
	H_0 為真	H_a 為真
接受	正確判定	型二誤
拒絕	型一誤	正確判定


附註

- 型一誤及型二誤無法同時變小
- 一般設定
 - 型一誤為固定（顯著水準=0.05）
 - 選擇檢定統計量會讓型二誤最小（檢定力最大）



P 值 (顯著性)

- 檢定統計通常會有特定分配，計算 p 值方便使用判定結論
- P 值為原來檢定分配會超過目前觀察到的觀察值所對應的檢定值的機率



Z_α 為臨界值

中央極限定理

中央極限定理

- 考慮一組隨機樣本 $x_1, x_2, \dots, x_n$ 取自母體
 - 平均值 μ
 - 變異數 σ^2
- 只要樣本 (n) 夠大, 則樣本平均數 $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ 的分配為常態分配, 其中
 - 平均值 μ
 - 變異數 σ^2 / n
 - 標準誤 $\sigma / \sqrt{n}$

單一樣本

統計推論 -- 連續變數

假設

- 考慮一個常態的樣本 $x_1, \dots, x_n$
- 平均值為 μ_x
- 變異數為 σ_x^2
- 設 μ_0 為已知數
- 考慮假設

$$H_0 : \mu_x = \mu_0 \quad \text{vs} \quad H_a : \mu_x \neq \mu_0$$

T 檢定 (σ_x^2 未知)

- 定義

$$T = \frac{\bar{X} - \mu_0}{s_x / \sqrt{n}} \xrightarrow{a} t_r$$

其中 t_r 為自由度為 $r = n-1$ 的 t 分配,

$$s_x^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

- 拒絕域

$$|T| \geq t_{\alpha/2, r}$$

信賴區間 (小樣本)

• 因

$$T = \frac{\bar{X} - \mu}{s_x / \sqrt{n}} \longrightarrow t_{n-1}$$

可得
$$P\left[\left|\frac{\bar{X} - \mu}{s_x / \sqrt{n}}\right| \leq t_{n-1; \alpha/2}\right] = 1 - \alpha$$

μ 的 $(1 - \alpha)\%$ 信賴區間為

$$\left(\bar{x} - t_{n-1; \alpha/2} \frac{s_x}{\sqrt{n}}, \bar{x} + t_{n-1; \alpha/2} \frac{s_x}{\sqrt{n}} \right)$$

信賴區間 (大樣本)

• 因

$$Z = \frac{\bar{X} - \mu}{s_x / \sqrt{n}} \xrightarrow{a} N(0,1)$$

$$P\left[\left|\frac{\bar{X} - \mu}{s_x / \sqrt{n}}\right| \leq z_{\alpha/2}\right] = 1 - \alpha$$

可 μ 的 $(1 - \alpha)\%$ 信賴區間為

$$\left(\bar{x} - z_{\alpha/2} \frac{s_x}{\sqrt{n}}, \bar{x} + z_{\alpha/2} \frac{s_x}{\sqrt{n}} \right)$$

語法

```
PROC TTEST < options > ;  
  CLASS variable ;  
  PAIRED variables ;  
  BY variables ;  
  VAR variables ;  
  FREQ variable ;  
  WEIGHT variable ;
```

PROC 選項

選項	說明
$DATA=SAS-data-set$	設定資料集
$ALPHA=p$	設定信賴水準
$H_0=m$	設定虛無假設的母體平均值

CLASS 說明

- 宣告變數為類別變數
- 類別只能有二類
- 用在二個樣本 T 檢定

PAIRS 設定

These PAIRED statements... yield these comparisons

PAIRED A*B;	A-B
PAIRED A*B C*D;	A-B and C-D
PAIRED (A B)*(C D);	A-C, A-D, B-C, and B-D
PAIRED (A B)*(C B);	A-C, A-B, and B-C
PAIRED (A1-A2)*(B1-B2);	A1-B1, A1-B2, A2-B1, and A2-B2
PAIRED (A1-A2):(B1-B2);	A1-B1 and A2-B2

範例

- 檢測平均城市里程數是否等於 20 哩每加侖？
- 資料集 –
statpackch7d1

```
proc ttest  
data=ch7d1  
H0=20;  
  
var mpg_city;  
  
run;
```

範例 – 報表輸出

變數: MPG_City (MPG (City))

N	平均	標準差	標準誤差	Minimum	Maximum
428	20.0607	5.2382	0.2532	10.0000	60.0000

平均	95% CL 平均值		標準差	95% CL 標準差	
20.0607	19.5631	20.5584	5.2382	4.9092	5.6148




DF	t 值	Pr > t
427	0.24	0.8105

不拒絕 H_0 , 平均里程數與 20 公里每加侖沒有明顯差異

二個獨立樣本

統計推論 -- 連續變數

情境



假設

- 考慮兩個常態的樣本 $x_1, \dots, x_{n_1}; y_1, \dots, y_{n_2}$
- 平均值為 μ_x, μ_y
- 變異數為 σ_x^2, σ_y^2
- 考慮假設

$$H_0 : \mu_x = \mu_y \quad \text{vs} \quad H_a : \mu_x \neq \mu_y$$

變異數相等 F 檢定

- 樣本變異數會影響 T 檢定的建構
- 考慮假設

$$H_0 : \sigma_x = \sigma_y \text{ vs } H_a : \sigma_x \neq \sigma_y$$

- 定義

$$F = \frac{s_x^2}{s_y^2} \sim F_{n_1-1, n_2-1}$$

其中 s_x^2 及 s_y^2 是樣本變異數

兩個樣本 T 檢定(變異數不相等)

- 定義

$$T = \frac{\bar{X} - \bar{Y}}{\sqrt{\frac{s_x^2}{n_1} + \frac{s_y^2}{n_2}}} \rightarrow t_{df}$$

其中 $\bar{X}$ 及 $\bar{Y}$ 是樣本平均值，df 的近似值為

$$\left[\frac{s_x^2}{n_1} + \frac{s_y^2}{n_2} \right]^2 \bigg/ \frac{\left(\frac{s_x^2}{n_1} \right)^2}{n_1 - 1} + \frac{\left(\frac{s_y^2}{n_2} \right)^2}{n_2 - 1}$$

兩個樣本 T 檢定(變異數相等)

- 定義

$$T = \frac{\bar{X} - \bar{Y}}{s_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \rightarrow t_{df}$$

其中

$$s_p^2 = \frac{(n_1 - 1)s_x^2 + (n_2 - 1)s_y^2}{n_1 + n_2 - 2}$$

是整合的樣本變異數 (pooled sample variance) ，而
 $df = n_1 + n_2 - 2$

信賴區間(變異數不相等)

• 因

$$P\left[\left|\frac{\bar{X} - \bar{Y} - (\mu_x - \mu_y)}{\sqrt{s_x^2/n_1 + s_y^2/n_2}}\right| \leq t_{df, \alpha/2}\right] = 1 - \alpha$$

$\mu_x - \mu_y$ 的 $(1-\alpha)\%$ 信賴區間為

$$\left(\bar{x} - \bar{y} - t_{df, \alpha/2} \sqrt{\frac{s_x^2}{n_1} + \frac{s_y^2}{n_2}}, \bar{x} - \bar{y} + t_{df, \alpha/2} \sqrt{\frac{s_x^2}{n_1} + \frac{s_y^2}{n_2}}\right)$$

信賴區間(變異數相等)

• 因

$$P\left[\left|\frac{\bar{X} - \bar{Y} - (\mu_x - \mu_y)}{s_p \sqrt{1/n_1 + 1/n_2}}\right| \leq t_{n_1+n_2-2, \alpha/2}\right] = 1 - \alpha$$

$\mu_x - \mu_y$ 的 $(1-\alpha)\%$ 信賴區間為

$$\left(\bar{x} - \bar{y} - t_{n_1+n_2-2, \alpha/2} s_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}, \bar{x} - \bar{y} + t_{n_1+n_2-2, \alpha/2} s_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}\right)$$

範例

- 檢測汽車驅動方式是否與城市哩程數有關？

```
proc ttest  
    data=ch7d1;  
Class  
    drivetrain;  
var mpg_city;  
run;
```

範例－檢定

方法	變異數	DF	t 值	Pr > t
集區	均等	334	7.03	<.0001
Satterthwaite	不均等	326.62	9.04	<.0001

變異數相等性				
方法	Num DF	Den DF	F 值	Pr > F
摺疊的 F	225	109	5.98	<.0001

- F 檢定顯著性 <0.0001 表示分汽車驅動方式，城市哩程數之變異數之間有顯著差異
- 使用變異數不相等的 T 檢定
- T 檢定顯著性 <0.0001 表示不同汽車驅動方式會明顯有不同平均城市哩程數

範例 -- 信賴區間

DriveTrain	方法	平均	95% CL 平均值		標準差	95% CL 標準差	
Front		22.2566	21.4801	23.0332	5.9244	5.4239	6.5274
Rear		18.1273	17.6693	18.5853	2.4235	2.1401	2.7942
Diff (1-2)	集區	4.1294	2.9732	5.2856	5.0558	4.6997	5.4706
Diff (1-2)	Satterthwaite	4.1294	3.2307	5.0281			

附註


- 每個樣本所來的母體分配為常態
- 檢查分配需針對每個樣本
- 檢驗分配前，樣本需依據組別排序

非對稱分配的補救措施


- 利用無母數檢定
- 利用變數變換

變數變換

- 對數轉換可將右偏資料轉為對稱



Log plasma beta-carotene (ng/ml)



Plasma beta-carotene (ng/ml)

常態檢定

常態假設


- 許多統計檢定是在母體為常態的假設下建構
- 檢測常態的工具
 - 圖示法
 - QQ 圖 / P-P圖
 - 直方圖
 - 檢定
 - Shapiro Wilk 檢定 (W檢定)
 - Kolmogorov-Smirnov 檢定
 - Cramer-von Mises 檢定
 - Anderson-Darling 檢定

範例


- 檢測里程數是否服從常態分配?
- 資料集 –
statpackch7d1

```
proc univariate  
  data=ch7d1  
  normal;  
var mpg_city;  
histogram  
  mpg_city  
  /normal;  
qqplot  
  mpg_city;  
run;
```

範例－城市哩程數的直方圖



範例 -- 城市哩程數的 QQ 圖



範例一 常態檢定

常態性檢定				
檢定	統計值		p 值	
Shapiro-Wilk	W	0.80784	Pr < W	<0.0001
Kolmogorov-Smirnov	D	0.178848	Pr > D	<0.0100
Cramer-von Mises	W-Sq	2.686108	Pr > W-Sq	<0.0050
Anderson-Darling	A-Sq	14.67298	Pr > A-Sq	<0.0050

無母數檢定

假設

- 考慮兩個樣本 $x_1, \dots, x_{n_1}; y_1, \dots, y_{n_2}$
- 中位數為 m_x, m_y
- 考慮假設

$$H_0 : m_x = m_y \quad \text{vs} \quad H_a : m_x \neq m_y$$

範例

- 考慮二組隨機樣本

$$x_1 = 78, x_2 = 65, x_3 = 74, x_4 = 45, x_5 = 82$$

$$y_1 = 110, y_2 = 71, y_3 = 53, y_4 = 50$$

- 合併排名結果

45	50	53	65	71	74	78	82	110
x	y	y	x	y	x	x	x	y
1	2	3	4	5	6	7	8	9

- 各組平均排名

$$\bar{R}_x = (7 + 4 + 6 + 1 + 8) / 5 = 26 / 5 = 5.2$$

$$\bar{R}_y = (9 + 5 + 3 + 2) / 4 = 19 / 4 = 4.75$$

簡單對數秩檢定

- 令 R_j 表示第 j 個資料的排名 (秩)
- 令 c_j 表示第 j 個資料的排名 (秩) 的加權分數
- 令 $a(R_j)$ 表示第 j 個資料的組別
- 定義

$$Z = \frac{S - E_0[S]}{\sqrt{\text{Var}_0(S)}} \xrightarrow{a} N(0,1)$$

其中

$$S = \sum_{i=1}^n c_i a(R_i);$$

$$E_0[S] = \frac{n_1}{n} \sum_{j=1}^n a(R_j);$$

$$\text{Var}_0(S) = \frac{n_1 n_2}{n(n-1)} \sum_{j=1}^n (a(R_j) - \bar{a})^2$$

Mann-Whitney (U) 檢定

- 先將兩組資料合併並排序
- 分組計算平均秩 (rank) 表示為 $\bar{R}_x$ 及 $\bar{R}_y$
- 定義

$$\frac{\bar{R}_x - \bar{R}_y}{(n_1 + n_2) \sqrt{\frac{n_1 + n_2 + 1}{12n_1n_2}}} \xrightarrow{a} N(0,1)$$

經驗分配

- 考慮一組樣本 $x_1, x_2, \dots, x_n$
由分配函數為 $F(x)$ 的母體選出
- 若對分配函數沒有任何資訊時，可利用
經驗分配函數來推估
- 定義經驗分配函數 (empirical
distribution function; EDF) 為


$$F_n(x) = \frac{1}{n} \sum_{i=1}^n I_{[x_i \leq x]}$$

範例

- 里程數的經驗分佈函數

```
proc freq  
data=ch7d1;  
table  
mpg_city/out=ou  
tch71 outcum;  
run;  
  
proc sgplot  
data=outch71;  
step x=mpg_city  
y=cum_pct;run;
```

範例－經驗分配



Kolmogorov-Smirnov 檢定

- 設有兩組資料之分佈函數分別為 $F(x)$ 及 $G(x)$
- 設有兩組資料之經驗分佈函數分別為 $F_n(x)$ 及 $G_n(x)$
- 考慮
$$H_0 : F(x) = G(x) \text{ vs } H_a : F(x) \neq G(x)$$
- 定義 KS 檢定

$$\sup_x |F_n(x) - G_n(x)| \xrightarrow{a} \text{Normal}$$

語法

```
PROC NPAR1WAY <options> ;  
BY variables ;  
CLASS variable ;  
EXACT statistic-options </ computation-  
  options> ;  
FREQ variable ;  
OUTPUT <OUT= SAS-data-set> <options> ;  
VAR variables ;
```

PROC 選項

選項	
DATA=	
MISSING	將遺失值當成一個組別
NOPRINT	
ALPHA	
CORRECT=NO	做連續校正

PROC 統計方法設定

選項	說明
ANOVA (預設)	利用原始資料產生單因子變異數分析 預設分數 (WILCOXON, MEDIAN, SAVAGE, and VW)
D	產生單邊 Kolmogorov-Smirnov 檢定
EDF (預設)	Kolmogorov-Smirnov 與 Cramer-von Mises 檢定是利用經驗分配計算

檢定位置參數

選項	檢定值
WILCOXON	利用秩 (RANK)
MEDIAN	為中位數的指標函數 $\Phi^{-1}\left(\frac{R_j}{n+1}\right)$
VW (NORMAL)	
SAVAGE	標準指數分配的順序統計量的期望值

檢定尺度參數

選項	
SIEGEL-TUKEY	$a(1) = 1, \quad a(n) = 2, \quad a(n-1) = 3, \quad a(2) = 4, \\ a(3) = 5, \quad a(n-2) = 6, \quad a(n-3) = 7, \quad a(4) = 8, \dots$
ANSARI-BRADLEY	$\frac{n+1}{2} - \left R_j - \frac{n+1}{2} \right $
KLOTZ	$\left(\Phi^{-1} \left(\frac{R_j}{n+1} \right) \right)^2$
MOOD	$\left(R_j - \frac{n+1}{2} \right)^2$

範例

- 檢測汽車驅動方式是否與城市里程數有關？

```
proc npar1way  
data=ch7d1  
wilcoxon;  
class drivetrain;  
var mpg_city;  
where  
drivetrain^='All';  
run;
```

範例－報表輸出

Wilcoxon 雙樣本檢定	
統計值	11447.0000
常態近似	
Z	-8.5261
單邊 Pr < Z	<.0001
雙邊 Pr > Z	<.0001
t 近似	
單邊 Pr < Z	<.0001
雙邊 Pr > Z	<.0001
Z 包含連續性校正 0.5。	

成對樣本

統計推論 -- 連續變數

假設

- 考慮成對常態的樣本 $(x_{11}, x_{21}), \dots, (x_{1n}, x_{2n})$
- 差值平均值為 μ_D
- 差值變異數為 σ_D^2
- 已知 μ_{D_0}
- 考慮假設

$$H_0 : \mu_D = \mu_{D_0} \quad \text{vs} \quad H_a : \mu_D \neq \mu_{D_0}$$

T 檢定 (σ_d^2 未知)

- 定義

$$T = \frac{\bar{d} - \mu_{D_0}}{s_d / \sqrt{n}} \xrightarrow{a} t_r$$

其中

$$\bar{d} = \frac{1}{n} \sum_{i=1}^n (x_{1i} - x_{2i}) = \frac{1}{n} \sum_{i=1}^n d_i$$

$$s_d^2 = \frac{1}{n-1} \sum_{i=1}^n (d_i - \bar{d})^2$$

t_r 為自由度為 $r=n-1$ 的 t 分配

信賴區間 (小樣本)

• 因

$$T = \frac{\bar{d} - \mu_D}{s_d / \sqrt{n}} \xrightarrow{a} t_r$$

可得

$$P \left[\left| \frac{\bar{d} - \mu_D}{s_d / \sqrt{n}} \right| \leq t_{n-1; \alpha/2} \right] = \alpha$$

μ_D 的 $(1-\alpha)\%$
為

信賴區間

$$(\bar{d} - t_{n-1, \alpha/2} s_d / \sqrt{n}, \bar{d} + t_{n-1, \alpha/2} s_d / \sqrt{n})$$

信賴區間 (大樣本)

- 因

$$Z = \frac{\bar{d} - \mu_D}{s_d / \sqrt{n}} \xrightarrow{a} N(0,1)$$

可得

$$P\left[\left|\frac{\bar{d} - \mu_D}{s_d / \sqrt{n}}\right| \leq z_{\alpha/2}\right] = 1 - \alpha$$

μ_D 的 $(1 - \alpha)\%$ 信賴區間為


$$(\bar{d} - z_{\alpha/2} s_d / \sqrt{n}, \bar{d} + z_{\alpha/2} s_d / \sqrt{n})$$

範例

- 比較吃藥前的血鉛含量是否有筆吃了8 周的藥高

```
proc gplot  
    data=ch7d2;  
plot lead6*lead0;  
run;  
  
proc ttest  
    data=ch7d2;  
paired  
    lead0*lead6;  
run;
```

範例－散佈圖



範例

The TTEST Procedure

Difference: lead0 - lead6

N	Mean	Std Dev	Std Err	Minimum	Maximum
50	5.7780	8.0457	1.1378	-30.2000	25.3000

Mean	95% CL Mean	Std Dev	95% CL Std Dev
5.7780	3.4914 8.0646	8.0457	6.7209 10.0260

DF	t Value	Pr > t
49	5.08	<.0001

離散反應變數

離散反應變數

單變量

二項式檢定

- 考慮一二元反應變數 $Y=0, 1$

- 令 $P[Y=1]=\pi; P[Y=0]=1-\pi$

- 考慮

$$H_0 : \pi = \pi_0 \text{ vs } H_a : \pi \neq \pi_0$$

- 令 $y_1, y_2, \dots, y_n$ 為隨機選取的樣本

- 定義比例檢定

$$Z = \frac{\hat{\pi} - \pi_0}{\sqrt{\hat{\pi}(1 - \hat{\pi}) / n}} \xrightarrow{a} N(0,1)$$

信賴區間

• 因
$$Z = \frac{\hat{\pi} - \pi_0}{\sqrt{\hat{\pi}(1 - \hat{\pi}) / n}} \xrightarrow{a} N(0,1)$$

得到
$$P\left[\left|\frac{\hat{\pi} - \pi_0}{\sqrt{\hat{\pi}(1 - \hat{\pi}) / n}}\right| \leq z_{\alpha/2}\right] = 1 - \alpha$$

所以 π 的 $(1 - \alpha)\%$ 信賴區間為

$$(\hat{\pi} - z_{\alpha/2} \sqrt{\hat{\pi}(1 - \hat{\pi}) / n}, \hat{\pi} + z_{\alpha/2} \sqrt{\hat{\pi}(1 - \hat{\pi}) / n})$$

卡方檢定

- 定義卡方檢定

$$\chi^2 = \frac{(n_1 - n\pi_0)^2}{n\pi_0} + \frac{(n_0 - n(1 - \pi_0))^2}{n(1 - \pi_0)} \xrightarrow{a} \chi_1^2$$

其中

$$n_0 = \# \text{ of } y_i = 0$$

$$n_1 = \# \text{ of } y_i = 1$$

$$n = n_1 + n_0$$

PROC FREQ

- 目的：產生相對頻率以及比例
- 語法：

```
PROC FREQ <options> ;  
BY variables ;  
EXACT statistic-options </ computation-  
options> ;  
OUTPUT <OUT= SAS-data-set> options ;  
TABLES requests </ options> ;  
TEST options ;  
WEIGHT variable </ option> ;
```

PROC 的選項

指令	說明
DATA	指定分析資料集
COMPRESS	令 SAS 將表格壓縮在一起
NOPRINT	不要產生任何輸出結果
ORDER=DATA FORMATTED FREQ INTERNAL	設定頻率表中類別的順序
PAGE	每一頁只列出一個變數的 頻率表

TABLE 的語法

設定	分析
tables A*(B C);	tables A*B A*C;
tables (A B)*(C D);	tables A*C B*C A*D B*D;
tables (A B C)*D;	tables A*D B*D C*D;
tables A -- C;	tables A B C;
tables (A -- C)*D;	tables A*D B*D C*D;

TABLES 的選項

指令	說明
BINOMIAL	檢定二項分配的比率
BINOMIALC	檢定二項分配的比率 (調整)
TESTP	設定多項分配期望機率
TETPF	設定多項分配期望頻率

TABLES 的選項

指令	說明
AGREE	產生同意性檢定
BDT	產生調整的同質檢定 (Tarone's adjustment for Breslow-Day test)
CHISQ	關聯性檢定
CMH	條件獨立檢定 (Cochran-Mantel-Haenszel statistic)
FISHER	費雪精確檢定
TREND	檢定線性關聯 (Cochran-Armitage test for trend)

以 TABLES 選項輸出檔案

指令	說明
OUT=	設定頻率表的輸出檔案
OUTCUM	輸出累積百分比
OUTEXPECT	輸出期望個數
OUTPCT	輸出列，行以及二維列聯表的細格百分比

範例

- 檢測選取的樣本比一般的民眾之 BMI 異常值 ($\pi_0 = 0.2$) 略高
- 資料集：statpackch7d3.txt

```
proc freq data=ch7d3;  
table bmigp1/binomial (p=0.2) ;  
run;
```

The FREQ Procedure

bmigp1	Frequency	Percent	Cumulative Frequency	Cumulative Percent
1	33	32.04	33	32.04
2	70	67.96	103	100.00

範例 - 二項式檢定

Binomial Proportion
for $\text{bmigp1} = 1$

Proportion	0.3204
ASE	0.0460
95% Lower Conf Limit	0.2303
95% Upper Conf Limit	0.4105

Exact Conf Limits	
95% Lower Conf Limit	0.2318
95% Upper Conf Limit	0.4196

Test of H_0 : Proportion = 0.2

ASE under H_0	0.0394
Z	3.0545
One-sided $\text{Pr} > Z$	0.0011
Two-sided $\text{Pr} > Z $	0.0023

Sample Size = 103

多項式檢定

- 考慮一多元反應變數 $Y=1, 2, \dots, c$
 - 球拍重量 (1=重; 2=正常; 3=輕)

- 令 $P[Y = j] = \pi_j, j = 1, \dots, c$

- 考慮

$$H_0 : \pi_j = \pi_{j0}, j = 1, \dots, c$$

VS

$$H_a : \text{at least one } j \text{ such that } \pi_j \neq \pi_{j0}$$

多項式檢定

- 令 $y_1, y_2, \dots, y_n$ 為隨機選取的樣本
- 令 n_i 表示該組樣本中 $y_j = i$ 的個數
- 定義卡方檢定

$$\chi^2 = \sum_{j=1}^c \frac{(n_j - n\pi_{j0})^2}{n\pi_{j0}} \xrightarrow{a} \chi_{c-1}^2$$

範例

- 檢測選取的樣本比一般的民眾之 BMI 分佈不同 $\pi_{10} = 0.2; \pi_{20} = 0.5; \pi_{30} = 0.3$
- 資料集：statpackch7d3.txt

```
proc freq data=ch7d3a;  
table bmigp/testp=(0.2,0.5,0.3);  
run;
```

範例

The FREQ Procedure

bmigp	Frequency	Percent	Test Percent	Cumulative Frequency	Cumulative Percent
1	15	14.56	20.00	15	14.56
2	70	67.96	50.00	85	82.52
3	18	17.48	30.00	103	100.00

Chi-Square Test for Specified Proportions

Chi-Square 13.5534
DF 2
Pr > ChiSq 0.0011

Sample Size = 103

二變量

離散反應變數

範例

- 探討影響網球肘 (有/沒有) 的可能因素
- 相關因素
 - 年齡 (年為單位)
 - 性別 (1=男; 2=女)
 - 球拍大小 (1=一般; 2=較大)
 - 球拍線的種類 (1=尼龍線; 2=腸線)
 - 球拍重量 (1=重; 2=正常; 3=輕)

列聯表(CONTINGENCY TABLE)

	1	2	...	J	合計
1	n_{11}	n_{12}		n_{1J}	n_{1+}
2	n_{21}	n_{22}		n_{2J}	n_{2+}
I	n_{I1}	n_{I1}		n_{IJ}	n_{I+}
合計	n_{+1}	n_{+2}	...	n_{+J}	n_{++}

範例

治療方式	成功	失敗
A	20	20
B	20	40

獨立性檢定

- 用來檢驗二個類別型變數 (X, Y) 之間的關聯程度
- 考慮

$H_0 : X$ 與 Y 獨立

$H_a : X$ 與 Y 不獨立

環境及符號設定

- 考慮反應變數及解釋變數均有二個類別
- 令 π_{ij} 表示每種分類方式會發生的機率
- 令 n_{ij} 表示每種分類方式的樣本人數
- 令 π_{i+} 表示列分類方式會發生的機率
- 令 π_{+j} 表示欄分類方式會發生的機率

	成功	失敗	列總計
女	$n_{11} \quad \pi_{11}$	$n_{12} \quad \pi_{12}$	$n_{1+} \quad \pi_{1+}$
男	$n_{21} \quad \pi_{21}$	$n_{22} \quad \pi_{22}$	$n_{2+} \quad \pi_{2+}$
欄總計	$n_{+1} \quad \pi_{+1}$	$n_{+2} \quad \pi_{+2}$	n_{++}

條件成功率及條件失敗率

- 令母體的條件成功率及失敗率為

$$P[\text{有網球肘} | \text{男}] = \pi_1$$

$$P[\text{沒有網球肘} | \text{男}] = 1 - \pi_1$$

$$P[\text{有網球肘} | \text{女}] = \pi_2$$

$$P[\text{有網球肘} | \text{女}] = 1 - \pi_2$$

- 樣本的條件成功率(估計值)為

$$\hat{\pi}_1 = \frac{n_{11}}{n_{1+}}$$

$$\hat{\pi}_2 = \frac{n_{21}}{n_{2+}}$$

即為列百分比

卡方檢定

- 定義卡方檢定

$$\chi^2 = \sum_{ij} \frac{(n_{ij} - \hat{E}_{ij})^2}{\hat{E}_{ij}} \xrightarrow{a} \chi^2_{(I-1)(J-1)}$$

- 其中

$$\hat{E}_{ij} = \frac{n_{i+} \times n_{+j}}{n_{++}}$$

範例

- 探討影響網球肘的可能因素
- 相關因素
 - 性別
 - 球拍線的種類
- 資料集：
statpackch7d3.xls

```
proc freq data=ch7d3;  
tables sex*event/chisq;  
run;
```

範例

FREQ 程序

次數 百分比 列百分比 欄百分比	Table of x3 by event			
	x3	event		總計
		0	1	
1		31	23	54
		31.31	23.23	54.55
		57.41	42.59	
		58.49	50.00	
2		22	23	45
		22.22	23.23	45.45
		48.89	51.11	
		41.51	50.00	
總計		53	46	99
		53.54	46.46	100.00

表格 event-x3*s 的統計值

統計值	自由度	值	機率
卡方	1	0.7160	0.3974
概度比卡方	1	0.7164	0.3973
連續性調整卡方	1	0.4145	0.5197
Mantel-Haenszel 卡方	1	0.7088	0.3998
Phi 係數		0.0850	
列聯係數		0.0847	
Cramer V		0.0850	